

SAE 1.05

Traiter des donnees

Rapport de projet - Analyse et gestion des gros fichiers

Etudiant	Quentin ALTINOK
Binome	Mathis BILON et Quentin ALTINOK
Formation	BUT Reseaux & Telecommunications - IUT de Colmar
Semestre	Semestre 1 - BUT 1
Competence principale	C3 - Programmer / traiter des donnees
Technologies	Python 3, pathlib, JSON, PyQt5, PyQtChart, PowerShell Core

Ce rapport presente la conception d'un outil de reporting permettant de parcourir un repertoire, d'identifier les fichiers les plus volumineux, d'afficher les resultats dans une interface graphique et de generer un script PowerShell de suppression securisee.

1. Contexte et problematique

Dans un environnement informatique, le manque d'espace disque peut empecher l'installation d'applications, les mises a jour ou le bon fonctionnement d'un poste. La difficulte principale est de localiser rapidement les fichiers volumineux dans une arborescence qui peut contenir beaucoup de sous-dossiers.

La SAE 1.05 demandait de developper un outil de reporting capable d'analyser un repertoire de base, de parcourir recursivement les sous-repertoires, de reperer les gros fichiers et de presenter les resultats de maniere lisible. Le projet devait aussi permettre de preparer la suppression de certains fichiers, mais de facon prudente afin d'eviter la suppression de fichiers systeme ou importants.

Objectifs du projet

- Permettre a l'utilisateur de choisir un repertoire de base a analyser.
- Parcourir toute l'arborescence du repertoire de facon recursive.
- Recuperer pour chaque fichier son chemin complet et sa taille en octets.
- Trier les fichiers du plus volumineux au plus petit.
- Conserver uniquement les fichiers depassant un seuil donne et limiter la liste aux 100 plus gros fichiers.
- Enregistrer les resultats dans un fichier JSON.
- Afficher les resultats dans une interface graphique avec un camembert et des legendes interactives.
- Generer un script PowerShell de suppression uniquement pour les fichiers coches par l'utilisateur.

2. Cahier des charges et contraintes

Le cahier des charges impose une organisation en plusieurs scripts. PowerShell sert de point d'entree pour lancer l'outil, tandis que Python realise la selection du dossier, l'analyse des fichiers, la creation du JSON et l'interface graphique.

Element attendu	Mise en oeuvre dans le projet
Selection du repertoire	Ouverture d'une boite de dialogue PyQt5 avec <code>QFileDialog.getExistingDirectory()</code> .
Analyse recursive	Parcours du repertoire de base avec <code>pathlib</code> et <code>rglob("**")</code> .
Tri et filtrage	Classement decroissant par taille, seuil minimal et limitation aux 100 fichiers les plus volumineux.
Stockage	Creation d'un fichier JSON contenant les couples [chemin complet, taille en octets].
Interface graphique	Fenetre PyQt avec onglets, graphique circulaire, pages de legendes et cases a cocher.
Suppression	Generation d'un script PowerShell avec confirmations avant <code>Remove-Item</code> .
Multiplateforme	Utilisation de <code>pathlib</code> pour limiter les problemes de chemins Windows, Linux et macOS.

3. Architecture du projet

Le projet a été pensé comme une chaîne de traitement. Chaque partie a un rôle précis : PowerShell lance le processus, Python analyse les données, JSON sert de format d'échange, PyQt présente les résultats et PowerShell est réutilisé pour la suppression sécurisée.




Figure 1 - Pipeline de traitement : PowerShell, Python, JSON, PyQt et suppression.

Etape	Role
PowerShell	Lance les scripts Python et sert d'interface de controle pour les actions sensibles.
Selection du dossier	Un premier script Python retourne le repertoire de base choisi par l'utilisateur.
Analyse Python	Un second script inventorie les fichiers, calcule leurs tailles et trie les resultats.
JSON	Le fichier JSON stocke les resultats et permet de les reutiliser dans l'interface.
PyQt / PyQtChart	L'interface affiche un camembert, des legendes et des cases a cocher.
Suppression	Un script PowerShell est genere pour supprimer uniquement les fichiers selectionnes.

4. Technologies utilisees

Technologie	Utilisation
Python 3	Langage principal pour analyser les fichiers, trier les données et créer le fichier JSON.
pathlib	Gestion propre et multiplateforme des chemins et parcours récursif des dossiers.
JSON	Format semi-structure pour stocker les chemins et tailles des fichiers trouvés.
PyQt5	Création de la fenêtre, des onglets, des boutons, des cases à cocher et des zones de texte.
PyQtChart	Création du graphique circulaire représentant la répartition des tailles.
PowerShell Core	Lancement de l'outil et génération du script de suppression.

5. Mise en oeuvre technique

5.1 Analyse recursive des fichiers

L'analyse consiste à parcourir le repertoire de base et tous ses sous-repertoires. Pour chaque element rencontre, le programme verifie qu'il s'agit bien d'un fichier, recupere son chemin complet et sa taille en octets, puis ajoute ces informations dans une liste.

```
from pathlib import Path

def analyse_repertoire(repertoire_base):
    fichiers = []
    base = Path(repertoire_base)
    for element in base.rglob("*"):
        if element.is_file():
            fichiers.append([str(element.resolve()), element.stat().st_size])
    return fichiers
```

5.2 Tri, filtrage et limitation

Les fichiers sont tries par taille decroissante. Ensuite, l'outil conserve uniquement les fichiers dont la taille depasse un seuil defini en MiB, puis limite le resultat aux 100 premiers fichiers afin de garder une interface exploitable.

```
def filtre_gros_fichiers(liste_fichiers, seuil_mib=1, nb_max=100):
    seuil_octets = seuil_mib * 1024 * 1024
    tri = sorted(liste_fichiers, key=lambda fichier: fichier[1], reverse=True)
    return [f for f in tri if f[1] >= seuil_octets][:nb_max]
```

5.3 Ecriture et lecture du fichier JSON

Le fichier JSON sert de point de passage entre l'analyse et l'affichage graphique. Il contient une liste de listes, chaque sous-liste ayant le chemin complet du fichier et sa taille en octets.

```
import json

def ecrit_json(liste_fichiers, nom_json):
    with open(nom_json, 'w', encoding='utf-8') as f:
        json.dump(liste_fichiers, f, indent=2, ensure_ascii=False)

def lit_json(nom_json):
    with open(nom_json, 'r', encoding='utf-8') as f:
        return json.load(f)
```

5.4 Generation du script PowerShell

La suppression n'est pas executee directement par l'interface. L'application genere un script PowerShell contenant les fichiers coches et demande une double confirmation avant toute suppression. Ce choix limite les risques d'erreur.

```
Write-Output "Script PowerShell pour supprimer des fichiers"
$reponse = Read-Host "Confirmer la suppression ? (OUI)"
if ($reponse -eq "OUI") {
    $confirmation = Read-Host "Etes-vous certain ? (OUI)"
    if ($confirmation -eq "OUI") {
        Remove-Item -Path "C:\TEMP\UPL\log.txt" -Force
    }
}
```

6. Interface graphique et resultats

L'interface graphique permet de rendre les resultats plus lisibles. Le camembert montre la part de chaque fichier volumineux dans le total analyse. Les onglets de legendes permettent d'afficher les fichiers par groupes de 25, avec une case a cocher pour preparer une suppression.




Figure 2 - Interface graphique avec camembert et liste des fichiers volumineux.

Fonctionnalites visibles dans l'interface

- Affichage d'un graphique circulaire representant la repartition des tailles.
- Affichage des chemins et tailles de fichiers dans une liste de legendes.
- Utilisation de cases a cocher pour selectionner les fichiers a supprimer.
- Affichage du repertoire de base analyse.
- Generation d'un script PowerShell uniquement pour les fichiers selectionnes.

7. Tests et validation

Les tests se sont concentres sur la coherence des resultats et la securite de l'outil. Il fallait verifier que le parcours recursif n'oubliait pas de fichiers, que le tri placait bien les fichiers les plus volumineux en premier, que le JSON etait correctement genere et que l'interface reprenait les bonnes donnees.

Test realise	Resultat attendu
Selection du repertoire	Le chemin choisi est bien transmis au script d'analyse.
Parcours recursif	Tous les fichiers du repertoire et des sous-repertoires sont listes.
Tri par taille	Les fichiers les plus volumineux apparaissent en premier.
Generation JSON	Le fichier contient les chemins complets et les tailles en octets.
Affichage PyQt	Le camembert et les legendes reprennent les donnees du JSON.
Cases a cocher	Seuls les fichiers coches sont ajoutes au script de suppression.
Script PowerShell	La suppression demande confirmation et n'est pas automatique.

8. Securite, limites et ameliorations possibles

L'outil manipule des fichiers potentiellement importants. Pour cette raison, la suppression est volontairement separee de l'analyse. L'utilisateur doit identifier les fichiers, cocher ceux qu'il souhaite supprimer, generer un script PowerShell, puis confirmer explicitement l'action.

Points de securite

- Aucun fichier n'est supprime automatiquement pendant l'analyse.
- La suppression passe par un script PowerShell lisible avant execution.
- Une double confirmation est demandee avant d'executer Remove-Item.
- L'utilisateur garde la responsabilite de verifier la nature des fichiers selectionnes.

Limites observees

- L'analyse peut etre longue sur de tres grandes arborescences ou sur des disques lents.
- Certains fichiers systeme peuvent etre inaccessibles a cause des droits utilisateur.
- L'interface peut devenir chargee lorsqu'il y a beaucoup de fichiers proches en taille.
- La suppression reste une operation sensible qui exige une verification manuelle.

Ameliorations possibles

- Ajouter une barre de recherche ou un filtre par extension.
- Afficher le type de fichier et la date de derniere modification.
- Ajouter un apercu avant suppression ou une corbeille temporaire.
- Ajouter une barre de progression pendant l'analyse.
- Ameliorer l'ergonomie de l'interface et rendre l'affichage plus responsive.

9. Competences developpees et bilan personnel

Cette SAE m'a permis de progresser en traitement de donnees avec Python. J'ai appris a manipuler des fichiers et des dossiers avec pathlib, a organiser des donnees dans des listes, a trier et filtrer des resultats, puis a les sauvegarder dans un fichier JSON. J'ai aussi decouvert la creation d'une interface graphique avec PyQt et l'utilisation de PowerShell pour automatiser des actions systeme.

Competences developpees

- Utiliser un systeme informatique et ses outils de script.
- Lire, corriger et modifier un programme Python.
- Traiter des donnees semi-structurees avec JSON.
- Manipuler des chemins de fichiers de maniere multiplateforme avec pathlib.
- Creer une interface graphique simple avec PyQt5 et PyQtChart.
- Automatiser une action systeme avec PowerShell tout en respectant des precautions de securite.

Bilan

Avec du recul, je separerais encore plus clairement les fonctions du projet des le debut : selection, analyse, filtrage, export JSON, interface et generation PowerShell. Cela rendrait le code plus facile a maintenir. Je ferais aussi des tests sur des arborescences de tailles differentes pour mieux mesurer les performances de l'outil.

Sources utilisees

Sujet SAE 1.05 - Creation d'un outil de reporting pour localiser les gros fichiers ; CM SAE R105 - Traitement des donnees ; TD1 PowerShell ; TD2 Traiter les donnees en Python ; support de presentation du projet SAE 1.05.